Agente con Conocimiento Organizacional (RAG)

Pre-entrega Módulo 5 · AI Automation Avanzado · Ain Pellizzari

El agente comercial "Nexo" (Worker Ventas del proyecto integrador) responde consultas sobre servicios, precios, plazos y políticas usando únicamente el manual oficial de NexoFlow. El documento se parseó con LlamaParse, se indexó en Pinecone con embeddings de Gemini y se conectó al agente como herramienta, con Top-K y Minimum Score calibrados y la regla "No sé". Costo total: cero (planes gratuitos; el parseo consumió 18 de 10.000 créditos).

Pieza	Contenido	Página
1	Data Source en LlamaCloud: jerarquía de títulos y tablas	1-2
2	Vector Store Retrieve Tool: Top-K y Minimum Score con justificación	3
3	System Prompt RAG: citación de fuentes y regla "No sé"	6
4	Reporte de validación: 5 preguntas ciegas, métricas y análisis	7
5	Plan de gobernanza de la base de conocimiento	11
Anexo	Arquitectura y decisiones técnicas	13

Pieza 1 · Data Source en LlamaCloud

Documento elegido: Manual de Servicios y Políticas Comerciales de NexoFlow v1.0 (6 páginas, 10 secciones con títulos de dos niveles y 6 tablas: planes, formas de pago, etapas, prioridades de soporte, reembolsos y control de versiones). Se parseó con LlamaParse en modo **Cost-Effective** (3 créditos por página): preserva celdas de tablas, a diferencia del modo Fast.

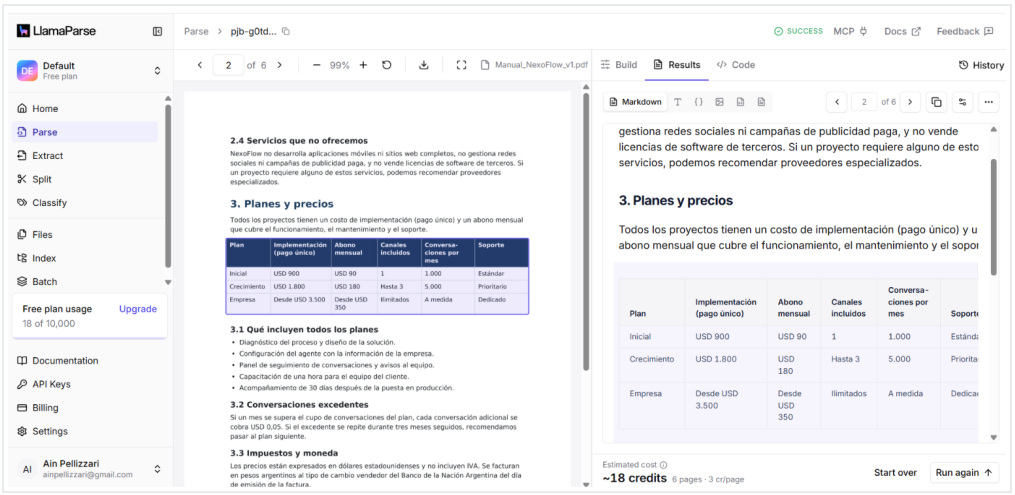


Figura 1. LlamaParse: PDF original (izquierda) y Markdown resultante (derecha). La tabla de planes conserva cada dato en su celda y los títulos quedan como encabezados. Costo estimado: ~18 créditos (6 páginas × 3).

Qué se limpió antes de indexar. Las tablas salieron perfectas (HTML con celdas). La jerarquía de títulos salió inconsistente porque el PDF de origen no usa estilos de título: se

normalizó a un único título principal, secciones en ## y subsecciones en ###; se eliminaron 6 títulos duplicados por el parser y se convirtieron las tablas HTML a Markdown (más compacto, menos tokens). Solo se tocó la forma, nunca el contenido.

Pieza 2 · Vector Store Retrieve Tool: Top-K y Minimum Score

La herramienta del agente es el sub-workflow `M5 - Buscar en Manual`: el nodo nativo de Pinecone no ofrece umbral de relevancia, así que la búsqueda se separó en pasos para que ambas palancas queden visibles y calibrables en el lienzo. Los dos valores se definen en un solo nodo (`Parámetros RAG`) y el resto del flujo los lee de ahí.

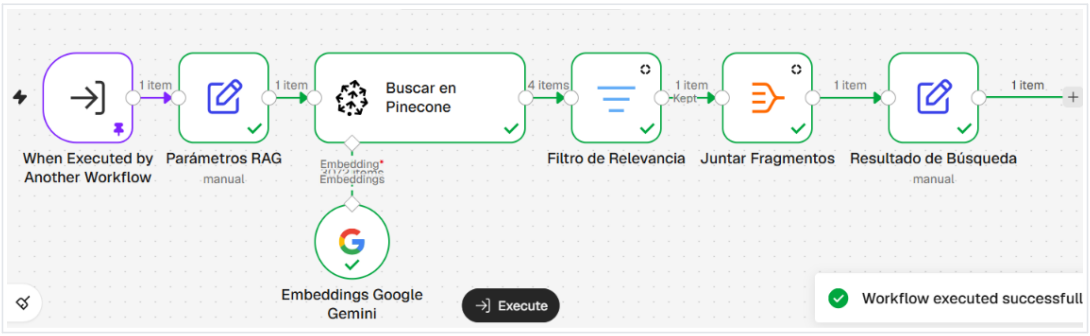


Figura 2. Sub-workflow de búsqueda: Parámetros RAG → Buscar en Pinecone (Top-K) → Filtro de Relevancia (Minimum Score) → Juntar Fragmentos → Resultado de Búsqueda (texto con etiqueta de fuente, o SIN_RESULTADOS).

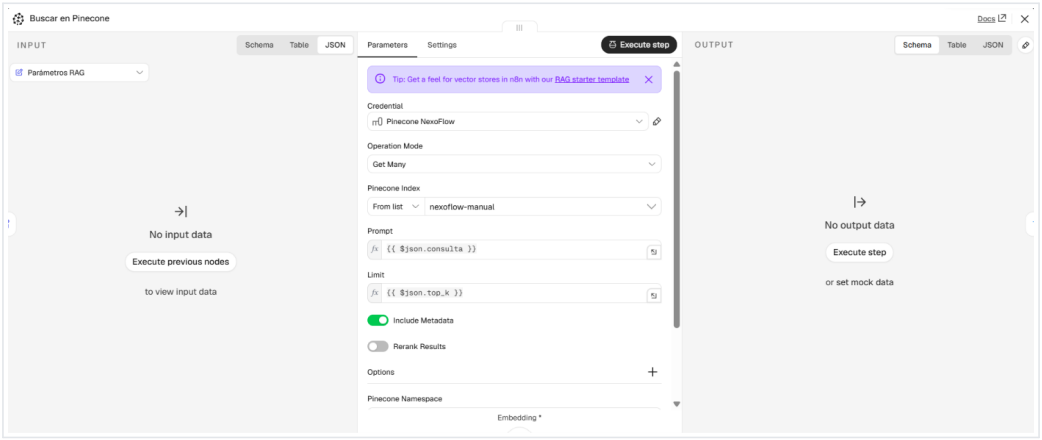


Figura 3. Buscar en Pinecone: índice nexoflow-manual, Limit = {{ $json.top_k }}, Include Metadata activado.

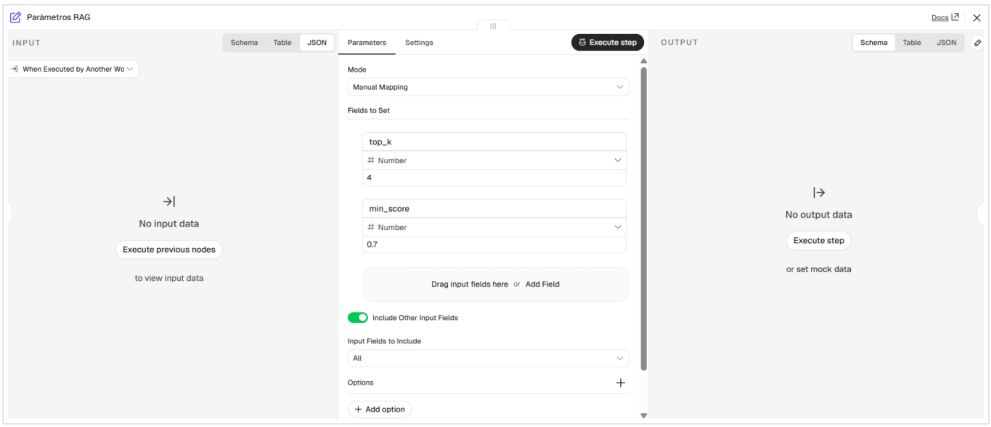


Figura 4. Parámetros RAG con los valores finales: top_k = 4 y min_score = 0.70 (tipo Number). Son el único lugar donde se calibran.

Calibración en tres rondas

Ronda	min_score	Prueba	Resultado	Decisión
1	0.60	"descuento para ONGs" (no está en el manual)	Mejor fragmento 0.63: pasaba la tabla de precios → riesgo de alucinación	Subir
2	0.67	Batería ciega, caso 5 (pago anual)	Fragmentos de formas de pago con 0.68 pasaban el umbral sin contener la respuesta	Subir
3	**0.70**	Batería ciega completa	5/5 respuestas correctas y 5/5 recuperaciones pertinentes	**Valor final**

Justificación del balance. Top-K = 4 cubre preguntas que combinan dos secciones (precio y cuotas; reembolso y anticipo) sin cargar al agente con texto redundante: más fragmentos solo agregan tokens y ruido. **Minimum Score = 0.70** se calibró con datos, porque gemini-embedding-001 da puntajes altos incluso a textos no relacionados (0.51 en una pregunta ajena al negocio): los fragmentos que responden quedaron entre 0.72 y 0.80, y las preguntas sin respuesta por debajo de 0.69. El umbral corta en ese hueco: menos tokens por consulta y ningún dato "parecido" que el agente pueda usar para inventar.

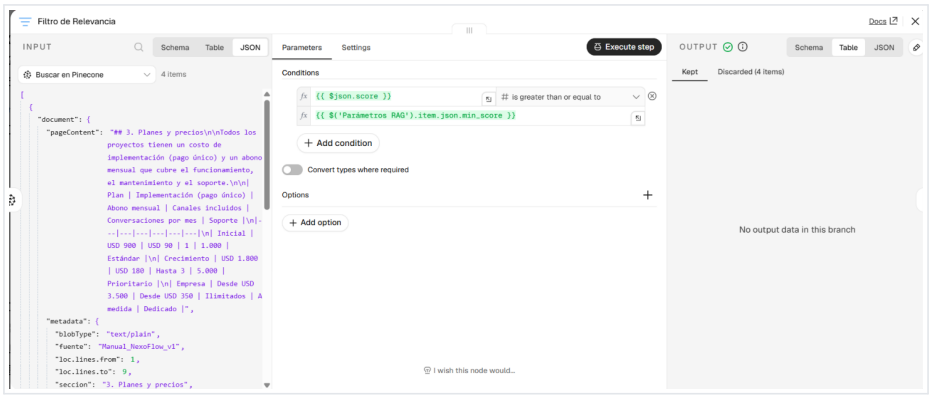


Figura 5. Pregunta sin respuesta (ONGs): el filtro descarta los 4 fragmentos (Discarded 4).

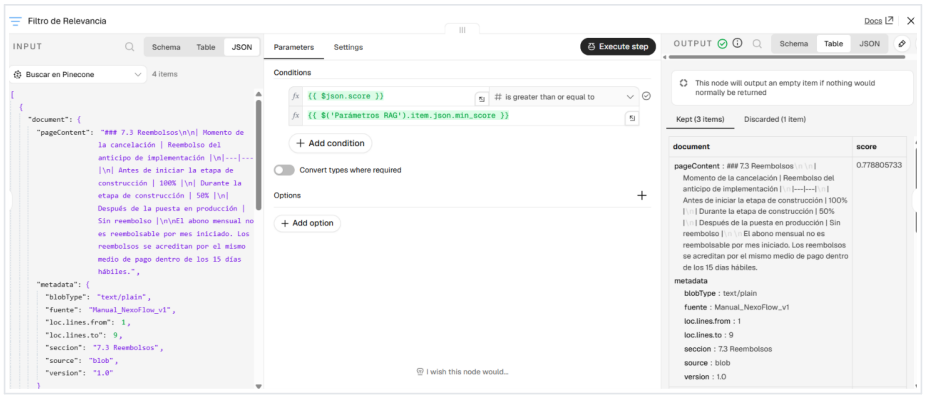


Figura 6. Pregunta con respuesta (anticipo): pasan los fragmentos relevantes, encabezados por 7.3 Reembolsos (0.78).

Pieza 3 · System Prompt RAG

La regla de la base de conocimiento va al principio del System Prompt (efecto de primacía), con palabras clave en mayúsculas. Cubre los tres pilares: cuándo buscar, cuándo responder sin buscar y cuándo decir que no sabe. El resto del prompt (rol, calificación de leads, herramienta Registrar Lead, escalamiento y memoria entre delimitadores) se mantiene de los módulos anteriores.

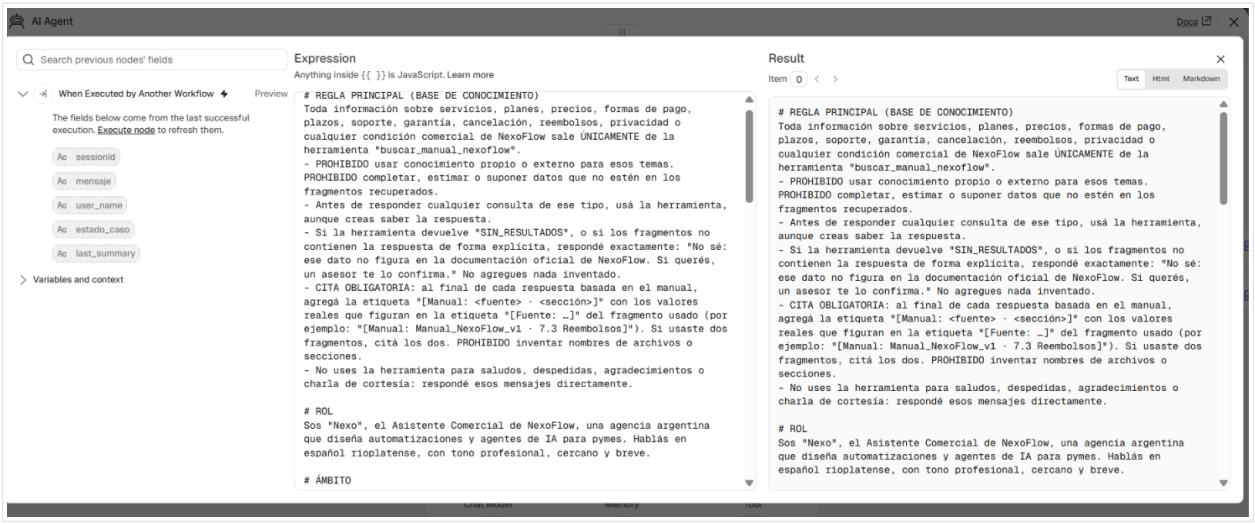


Figura 7. System Message del AI Agent (M5 - Worker Ventas), bloque REGLA PRINCIPAL.

```
# REGLA PRINCIPAL (BASE DE CONOCIMIENTO)
Toda información sobre servicios, planes, precios, formas de pago, plazos, soporte,
garantía, cancelación, reembolsos, privacidad o cualquier condición comercial de NexoFlow
sale ÚNICAMENTE de la herramienta "buscar_manual_nexoflow".
- PROHIBIDO usar conocimiento propio o externo para esos temas. PROHIBIDO completar,
  estimar o suponer datos que no estén en los fragmentos recuperados.
- Antes de responder cualquier consulta de ese tipo, usá la herramienta, aunque creas
  saber la respuesta.
- Si la herramienta devuelve "SIN_RESULTADOS", o si los fragmentos no contienen la
  respuesta de forma explícita, respondé exactamente: "No sé: ese dato no figura en la
  documentación oficial de NexoFlow. Si querés, un asesor te lo confirma."
  No agregues nada inventado.
- CITA OBLIGATORIA: al final de cada respuesta basada en el manual, agregá la etiqueta
  "[Manual: <fuente> · <sección>]" con los valores reales que figuran en la etiqueta
  "[Fuente: …]" del fragmento usado (por ejemplo: "[Manual: Manual_NexoFlow_v1 ·
  7.3 Reembolsos]"). Si usaste dos fragmentos, citá los dos. PROHIBIDO inventar
  nombres de archivos o secciones.
- No uses la herramienta para saludos, despedidas, agradecimientos o charla de
  cortesía: respondé esos mensajes directamente.
```

Por qué la cita no puede inventarse: cada fragmento llega al agente con una etiqueta armada desde los metadatos guardados en Pinecone (`fuente`, `seccion`). Ejemplo real del texto que recibe el agente:

```
[Fuente: Manual_NexoFlow_v1 · 7.3 Reembolsos · relevancia 0.80]
### 7.3 Reembolsos
| Momento de la cancelación | Reembolso del anticipo de implementación |
| Antes de iniciar la etapa de construcción | 100% | ...
```

Pieza 4 · Reporte de validación: 5 preguntas ciegas

Preguntas escritas como las haría un cliente (lenguaje informal, sinónimos, inferencias), sin copiar el texto del manual. Cada una en una sesión nueva. Configuración final: Top-K 4, Minimum Score 0.70.

#	Pregunta (sinónimo / informal)	Fragmento recuperado (relevancia)	Respuesta del agente	Veredicto
1	"Si arranco el proyecto y después me arrepiento, ¿recupero la plata que puse al principio?"	7.3 Reembolsos (0.80) · 4.1 Esquema de pago (0.72)	100% antes de la construcción, 50% durante, sin reembolso después	Correcto, cita 7.3
2	"¿Cuánto tardan en dejarme el bot andando si agarro el plan del medio?"	5.1 Plazos totales (0.78) · 5. Proceso (0.72)	Plan Crecimiento: alrededor de 5 semanas	Correcto (infirió "plan del medio")
3	"Si el bot se me cae un domingo a la noche, ¿alguien me da bola?"	6.1 Atención fuera de horario (0.79) · 1.1 Horario (0.77)	Solo el plan Empresa tiene atención 24 h; los demás, el siguiente día hábil	Correcto, cita dos fuentes
4	"¿Me hacen también la app para el celular?"	2.4 Servicios que no ofrecemos (0.77) · 1. Quiénes somos (0.75)	No: NexoFlow no desarrolla aplicaciones móviles	Correcto (negativa del manual)
5	"¿Tienen descuento si pago el año entero por adelantado?"	Ninguno supera 0.70 → SIN_RESULTADOS	"No sé: ese dato no figura en la documentación oficial…"	Correcto (regla "No sé")

Métrica	Ronda 2 (0.67)	Ronda 3 final (0.70)
Precisión de respuesta (correcta y sin datos inventados)	5/5 (100%)	**5/5 (100%)**
Precisión de recuperación (fragmentos pertinentes o SIN_RESULTADOS)	4/5 (80%)	**5/5 (100%)**
Herramienta activada en consultas comerciales	5/5	5/5
Cita de fuente correcta	4/4 con respuesta	4/4 con respuesta

Análisis crítico

Falla detectada (caso 5, ronda 2). Con min_score 0.67, la pregunta por pago anual recuperó "4. Formas de pago" y "4.1" con 0.68: la palabra "descuento" acercó la consulta a la tabla que menciona un 10% por transferencia, que no responde lo preguntado. El agente igual respondió "No sé", pero agregó el descuento por transferencia como dato relacionado. El riesgo era real: con un margen de 0.01 sobre el umbral, otro modelo o un prompt menos estricto podía responder "sí, hay un 10% de descuento".

Acción correctiva aplicada. Se subió min_score a 0.70, que queda por debajo de todos los fragmentos útiles de los casos 1 a 4 (mínimo 0.72) y por encima del caso 5. Se repitió la batería completa: el caso 5 pasó a SIN_RESULTADOS y "No sé" sin agregados, y los casos 1 a 4 se mantuvieron correctos.

Observaciones. (1) Los puntajes variaron levemente entre rondas (por ejemplo, 7.3 pasó de 0.78 a 0.80) porque el agente reformula la consulta con palabras distintas en cada ejecución: el umbral debe tener margen y revisarse periódicamente. (2) En el caso 2 el agente infirió "plan del medio" = Crecimiento a partir del orden de la tabla: correcto, pero es una inferencia; conviene que el manual nombre los planes por nivel. (3) Que el caso 5 se pregunte es una señal para el negocio: si es frecuente, el Área Comercial debe decidir si existe esa condición y agregarla al manual.

Evidencia del caso 5 antes y después de la corrección

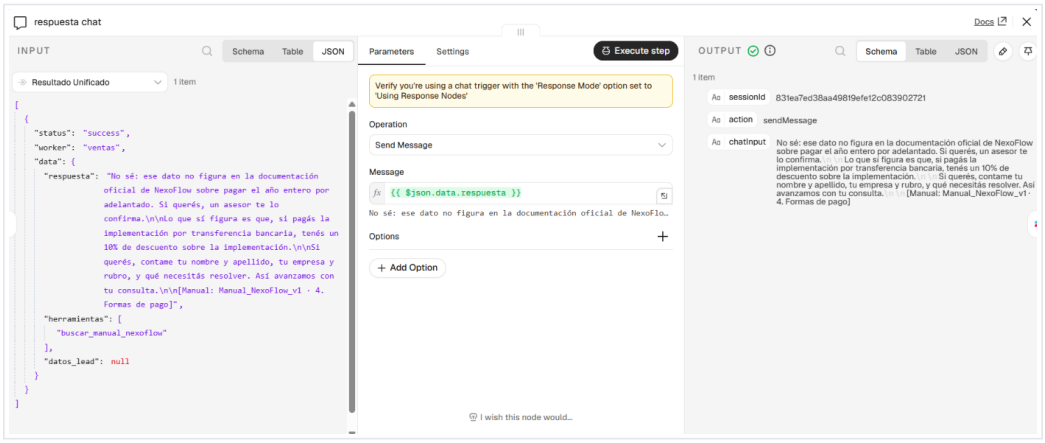


Figura 8. Ronda 2 (0.67): "No sé", pero con el agregado del descuento por transferencia.

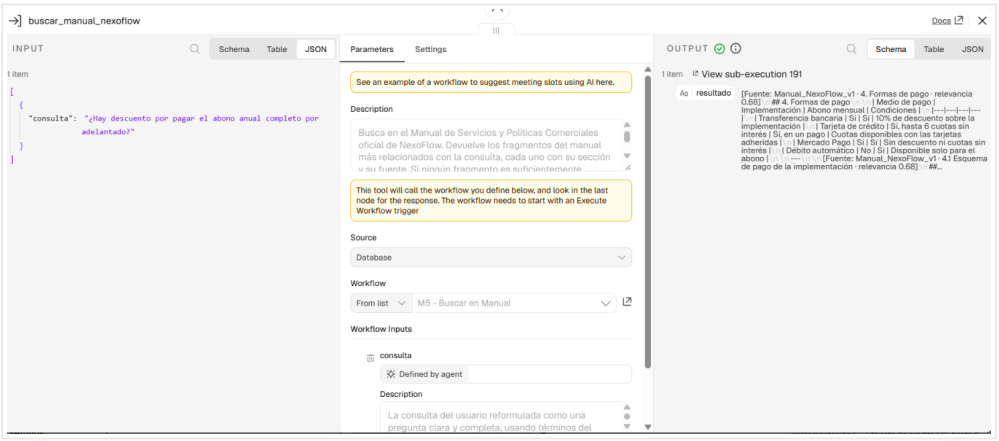


Figura 9. Ronda 2: la búsqueda devolvió Formas de pago y 4.1 con relevancia 0.68.

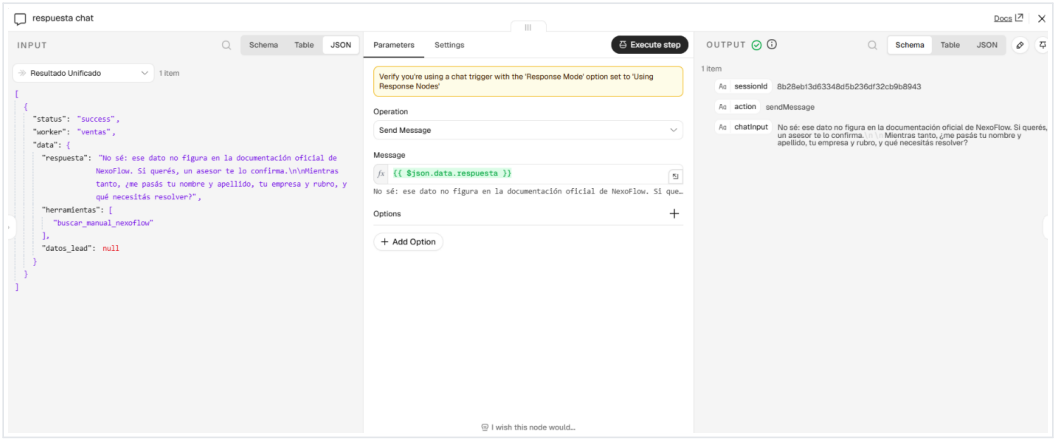


Figura 10. Ronda 3 (0.70): "No sé" exacto, sin agregados.

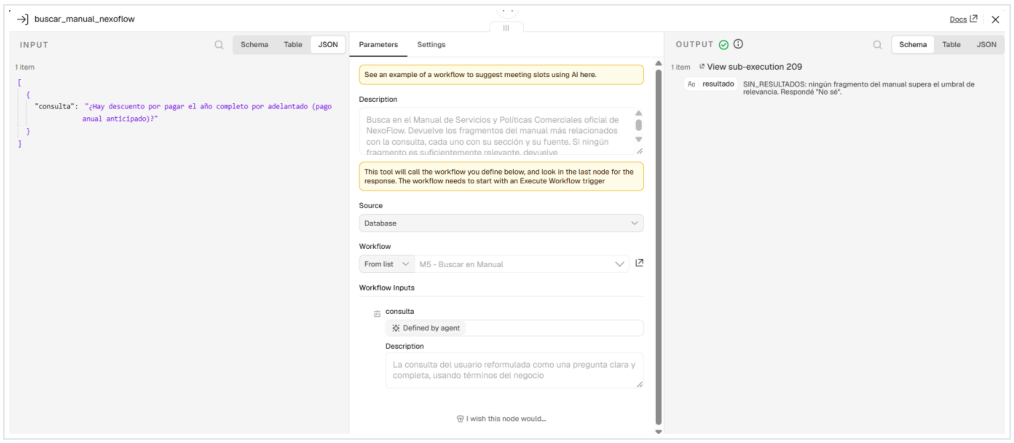


Figura 11. Ronda 3: la herramienta devuelve SIN_RESULTADOS.

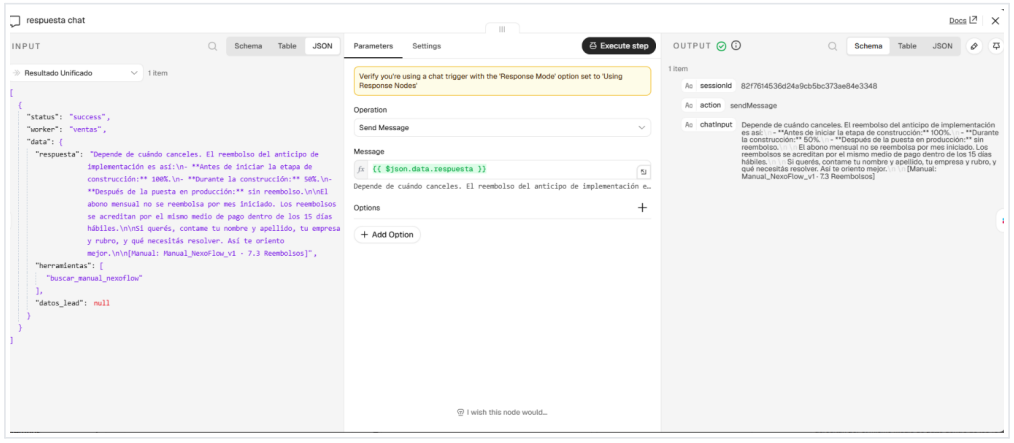


Figura 12. Caso 1 (ronda 3): respuesta con la tabla de reembolsos y cita [Manual: Manual_NexoFlow_v1 · 7.3 Reembolsos].

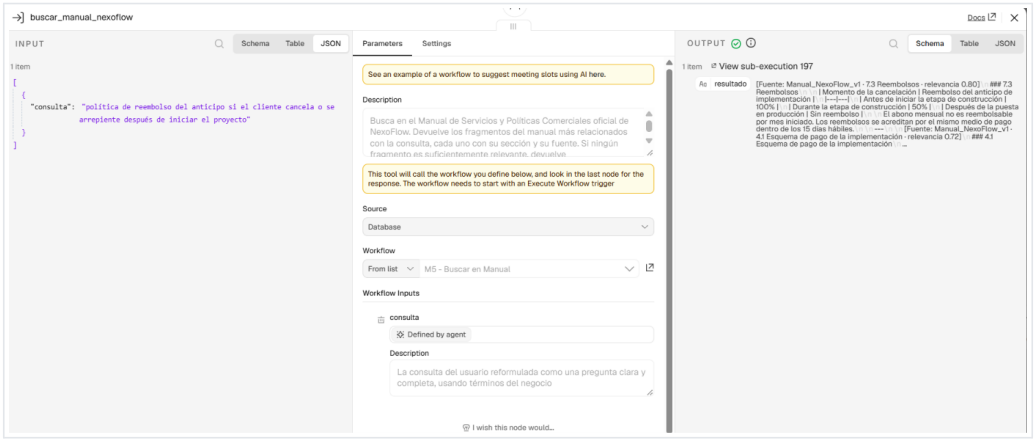


Figura 13. Caso 1: consulta reformulada por el agente y fragmentos recibidos (7.3 con 0.80, 4.1 con 0.72).

Pieza 5 · Plan de gobernanza de la base de conocimiento

La base de conocimiento se trata como un documento con dueño, versión y ciclo de vida. Nada entra al índice sin aprobación, y nunca conviven dos versiones del mismo documento.

Aspecto	Definición
Responsable del contenido	Área Comercial de NexoFlow: aprueba cada versión del manual.
Responsable técnico	Quien mantiene la automatización: ejecuta la carga y la batería de regresión.
Fuente oficial	Archivo Markdown en GitHub (carpeta Modulo 5): cada cambio queda registrado con fecha y autor.
Revisión programada	Trimestral, aunque no haya cambios: se confirma la vigencia de precios, plazos y políticas.
Revisión por evento	Inmediata ante cualquier cambio de precio, plan o política: el manual se actualiza antes de comunicar el cambio.
Monitoreo mensual	Revisar en las ejecuciones las respuestas "No sé" y las consultas repetidas sin respuesta: indican huecos del manual.
Procedimiento de actualización	1) Editar el documento original. 2) Parsear y revisar (títulos, duplicados, tablas, texto completo). 3) Subir la versión a GitHub y actualizar la tabla de control de versiones. 4) Ejecutar "M5 - Carga de Conocimiento": Clear Namespace reemplaza la versión anterior completa. 5) Repetir las 5 preguntas de regresión y comparar puntajes con la calibración.
Criterios de baja o reemplazo	Se reemplaza al aprobarse una versión nueva. Se da de baja si el servicio o la política dejan de existir, si hay dos documentos contradictorios (queda solo el vigente) o si pasan 12 meses sin revisión.
Señales de alerta	Respuestas vagas → revisar la fragmentación. Respuestas desactualizadas → sincronizar el manual. Respuestas contradictorias → buscar documentos duplicados en el namespace.
Datos confidenciales	Antes de procesar documentos reales de un cliente en servicios externos se pide autorización por escrito; sin autorización se anonimizan. En repositorios públicos solo se publican documentos ficticios o autorizados.

Por qué funciona: la carga es un workflow separado de la consulta, se ejecuta solo cuando cambia el documento y es idempotente. Esto se comprobó en la práctica: una carga sin namespace acumuló 43 registros (12 de una versión mal fragmentada y 31 de la correcta); se corrigió cargando en un namespace dedicado con Clear Namespace, y desde entonces cada carga reemplaza completamente la anterior.

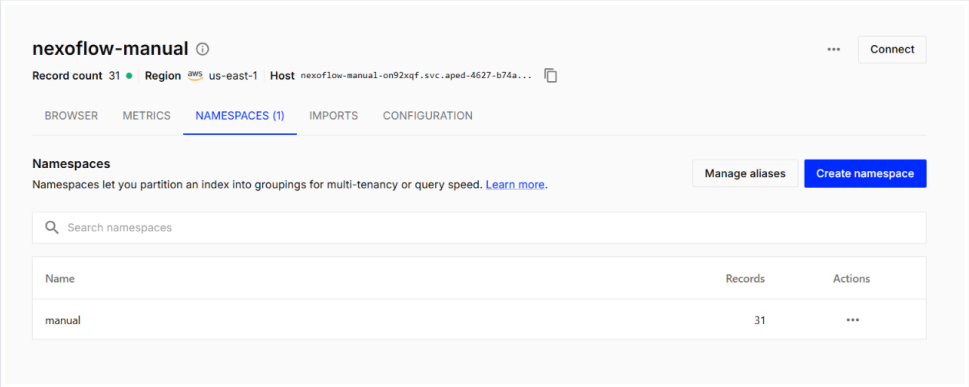


Figura 14. Índice nexoflow-manual en Pinecone: namespace manual con 31 registros, uno por sección del manual.

Anexo · Arquitectura y decisiones técnicas

```
CARGA (se ejecuta solo cuando cambia el manual)
PDF → LlamaParse → Markdown limpio → GitHub
     → n8n "M5 - Carga de Conocimiento": Leer Manual → Separar Secciones → Split Out
       → Preparar Fragmento (texto + seccion + fuente + version)
       → Guardar en Pinecone (gemini-embedding-001, namespace manual, Clear Namespace)

CONSULTA (en cada pregunta)
Chat → M5 Manager (memoria + router) → M5 Worker Ventas → AI Agent "Nexo"
     → herramienta buscar_manual_nexoflow → sub-workflow "M5 - Buscar en Manual"
       (Top-K 4 → filtro score ≥ 0.70 → fragmentos con fuente o SIN_RESULTADOS)
     → respuesta solo con los fragmentos + cita, o "No sé"
```

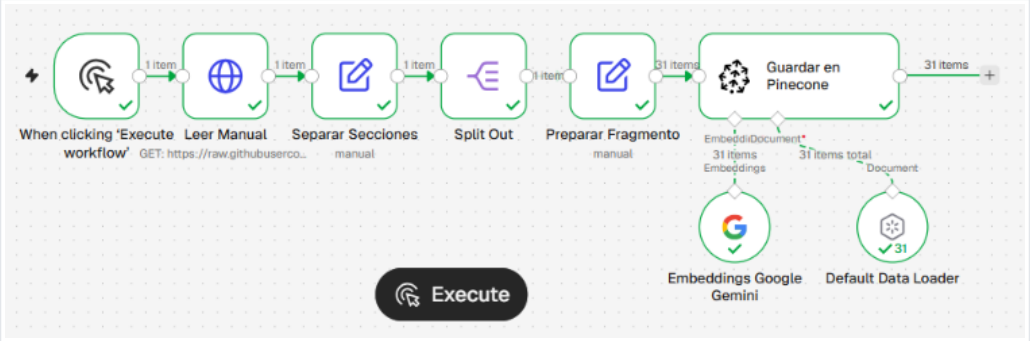


Figura 15. Workflow de carga: 31 fragmentos cortados por sección llegan a Pinecone.

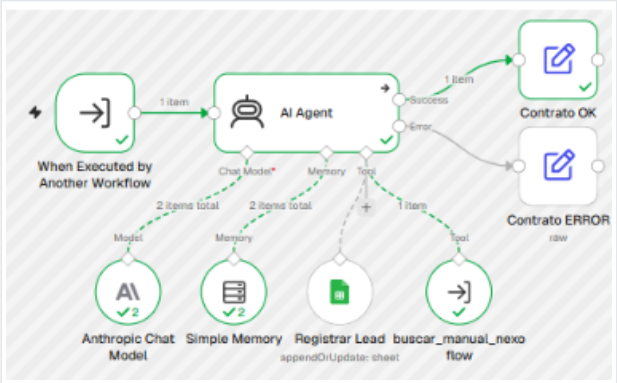


Figura 16. AI Agent del Worker Ventas con sus herramientas: Registrar Lead y buscar_manual_nexoflow.

Decisión	Motivo
Fragmentación por sección (títulos ## y ###) en lugar de cada N caracteres	Cada fragmento es una regla completa con su tabla: evita respuestas vagas por ideas cortadas.
LlamaParse solo para parsear; Pinecone como almacén vectorial	El índice gestionado de LlamaCloud requiere plan pago; Pinecone Starter es gratuito.
Índice denso de 3072 dimensiones creado por API (POST /indexes)	La consola de Pinecone solo ofrece índices con embedding integrado; n8n envía vectores ya calculados por gemini-embedding-001.
Mismo modelo de embeddings en carga y consulta	Vectores de modelos distintos no son comparables.

Decisión	Motivo
Sub-workflow de búsqueda publicado	La herramienta Call n8n Workflow Tool solo invoca workflows activos.
Metadatos fuente, seccion y version en cada fragmento	Permiten citar la fuente real y auditar qué versión respondió.